LLM Notes / LLM Notları

LLM: Models trained on large amounts of text data. They learn the structure of human language to produce meaningful, human-like text. Models like GPT4 were trained with 4 billion data. They take text as input and produce prediction-based text as output. Their basic structure is the transformer architecture. When we give a sentence, it tries to predict the next word, and this is done with billions of parameters.

> *LLM: Büyük miktarda metin veri ile eğitilmiş modellerdir. İnsan dilinin yapısını öğrenerek anlamlı ve insan benzeri metin üretmektir. GPT4 gibi modeller 4 milyar veri ile eğtilmiştir. Girdi olarak metin alırlar ve çıktı olarak tahmine dayalı metin üretirler. Temel yapıları transformer mimarisidir. Bir cümle verdiğimizde sıradaki kelimeyi tahmin etmeye çalışır ve bu olay milyarlarca parametre ile yapılır.*

fine-tuning: After the model has been pretrained, it is adjusted so that it performs specific tasks better. In this stage the model is trained with smaller data.

> *fine-tunning: Model ön eğitimde gerçekleştirildikten sonra belirli görevleri daha iyi yapması için ön ayar yapılır. Bu aşamada model daha küçük verilerle eğitilir.*

How LLMs work:

> *LLM'lerin çalışma prensipleri:*

1) Transformer architecture: It was developed as a solution to the limitations of earlier models such as RNN and LSTM. RNNs forget long context. It looks at all words at the same time, which provides both speed and power. It consists of two parts, Encoder and Decoder. The Encoder processes the incoming text and converts it into a meaning representation. The Decoder takes this representation and produces text. A self-attention mechanism works in every block, and the importance of words relative to each other is evaluated. Then a feedforward step is applied. As layers are stacked on top of each other, learning capacity increases. The attention mechanism is done with 3 key vectors to learn a word's relationship with other words. (Query(Q), key(K), Value(V)) This way the model understands which word it should pay attention to. Positional Encoding: the position of each word is added using sines and cosines. This way the model learns where in the sentence each word is.

> *1)Transformer mimari: Kendinden önceki RNN,LSTM gibi modellerin sınırlamalarına çözüm olarak geliştirilmiştir. RNN'ler uzun bağlamı unutur. Tüm kelimelere aynı anda bakar ve hem hız ve güç sağlar. Encoder ve Decoder iki kısımdan oluşur. Encoder gelen metni işler ve anlam temsiline dönüştürür. Decoder ise bu temsili alarak metin üretir. Her blokta self -attention mekanizması çalışır ve kelimelerin biribirine göre önemi değerlendilir. Ardından feedforward yapılır. Katmanlar üst üste bindikçe öğrenme kapasitesi artar. Atteniton mekanizması bir kelimenin diğer kelimeleerle ilişkisini öğrenmek için 3 anahtar vektör ile yapılır. (Query(Q) , key(K), Value(V)) Bu sayede model hangi kelimeye dikkat etmesi gerektiğini anlar.Positional Encoding her kelimenin konumu sin ve coslar ile eklenir. Bu sayede model hangi kelimenin cümlenin neresinde olduğunu öğrenir.*

2) Model Training:

> *2) Model Eğitimi:*

Pretraining: The model is trained with a very large and general dataset. This stage is very costly and difficult.

> *Pretraining: Model çok büyük ve genel bir veri kümesi ile eğitilir. Bu aşama çok maaliyetli ve zordur.*

fine-tuning: In this stage, we train the already-trained model by giving it the part we want it to learn.

> *fine-tunning: Bu aşamada eğitilen modele biz kendi öğrenmemizi istediğimiz kısmı vererek eğitiriz.*

inference: The stage where the model produces output.

> *inference: Modelin çıktı ürettiği aşamadır.*

A model trained from the internet may contain a lot of harmful, messy data. Data cleaning is essential.

> *internetten eğitilen bir model içinde çok fazla zararlı, düzensiz veri barındırabilir. Veri temizleme şarttır.*

When the model makes a prediction, it compares it with the correct answer. The difference is reduced through back propagation.

> *Model bir tahminde bulunduğunda doğru cevap ile karşılaştırır. Aradaki fark back propagation ile azaltılır.*

3) Tokenization and Data processing: AI models work with numbers. Words are first split into pieces and then converted into numbers; this is called tokenization. Word-based tokens treat words as tokens. Subword tokens treat syllables as tokens. Character-based tokens treat characters as tokens. Modern LLMs use subword tokens; this allows them to learn without memorizing all the words in a language. Every token is a cost. Broken tokens corrupt meaning.

> *3)Tokenizasyon ve Veri işleme: yapay zeka modelleri sayılarla çalışır. Kelimeler önce parçalara ayrılır ve sonrada sayılara çevrilir buna tokenizasyon denir. Kelime temelli tokenlar kelimeleri token olarak görür. Alt kelime tokenlar ise heceleri token olarak görür. karakter temelli token ise karakterleri token olarak görür. Modern LLM'ler subword tokenlar kullanırlar bu dildeki tüm kelimeleri ezberlemeden öğrenmelerine olanak tanır. Her token bir maaliyettir. Kırık tokenlar anlamı bozar.*

4) Inference: The stage of use after the model has been trained. It makes predictions with the structures it has learned. The prompt entering the inference is very important. A good prompt means good output.

> *4)Inference: Modelin eğitildikten sonra kullanım aşamsıdır. Öğrendiği yapılarla tahmin gerçekleştirir. Inference'ın girdiği prompt çok önemlidir. İyi prompt iyi çıktıdır.*

Sampling Strategies:

> *Sampling Stratejileri:*

Greedy decoding: the most probable word

> *Greedy decoding: en olası kelime*

Temperature: Randomness setting [0,1]. 0 guarantees no hallucination, 1 can be random.

> *Temperature: Rastgelelik ayarı[0,1] 0 garanti halisünasyon yok, 1 rastgele olabilir.*

Top-k top-p: narrowing the selection space.

> *Top-k top-p: seçim alanını daraltma.*

caching: storing past tokens

> *caching: geçmiş tokenlerin saklanması*

latency: the model's response time

> *latency: modelin yanıt verme süresi*

The inference output is chained token by token.

> *Inference çıktısı token token zincirlenir.*

5) Hallucination: An LLM producing information that does not exist in reality as if it were real, within a context. The hallucination risk increases in the training dataset. It can also be probability-based. If the model says so and does not cite a source, it may be a hallucination. Clear and explicit prompts should be written and work should be source-based; outputs should be evaluated once more thanks to fine-tuning and security layers.

> *5)Halüsinasyon: Bir LLM'in gerçekte olmayan bir bilgiyi gerçekmiş gibi bir bağlamda üretmesidir. Eğitim veri setinde halüsinasyon riski artar. Olasılık türünden de olabilir. Model böyle diyip kaynak göstermiyorsa halüsinasyon olabilir. Net ve açık prompt yazılmalı ve kaynak dayanaklı çalışılmalı, fine-tunning ve güvenlik katmanları sayesinde çıktıları bir kez daha değerlendirilmelidir.*

6) Gaining assistant behavior through fine-tuning: With fine-tuning, the model can be made to speak politely like an assistant and behave like an assistant.

> *6)Fine-tunning ile asistan davranışı kazandırma: fine tunning ile modele asistan gibi nazik konuşması, asistan gibi davranması sağlanabilir.*

7) Characteristics and Scaling Laws: The features that determine the character of an LLM

> *7)Karakteristikler ve Ölçekleme Kanunları: Bir LLM'in karakterini belirleyen özellikler*

number of parameters

> *parametre sayısı*

amount of training data

> *eğitim veri miktarı*

computing power

> *hesaplama gücü*

context disorder

> *bağlam bozukluğu*

As the model grows, accuracy and skill increase. Parameters, data and FLOPs must be scaled together.

> *Model büyüdükçe ve doğruluk beceri artar. Parametre, veri ve FLOPs birlikte ölçeklenmelidir.*

Training data must also be scaled. Diversity, cleanliness and task fit are important. Training with the same data creates a risk of overfitting.

> *Eğitim verisi de ölçeklenmelidir. Çeşitlilik, temizlik, görev uyumu önemlidir. Aynı veri ile eğitmek overfitting riski olur.*

An LLM does not reason; it recognizes patterns and produces reasoning-like outputs. Heuristic reasoning is choosing what works best instead of logic. Chain-of-thought reasoning is forcing step-by-step thinking.

> *LLM akıl yürütmez örüntü tanır ve akıl yürütme benzeri çıktılar üretir.Heuristik akıl yürütme mantık yerine en iişe yarayanı seçmedir. Zincirleme akıl yürütme adım adım düşünmeye zorlamaktır.*

AI agent: Tools that do not just respond but can communicate with the outside world. They are autonomous AI tools.

> *AI agent: LLM'in sadece yanıt vermekle kalmayıp dış dünya ile iletişime geçebilen araçlardır. Otonom yapay zeka araçlarıdır.*

LLM + Tool use = Agent

> *LLM+Araçkullanma=Agent*

An LLM makes a plan and produces it step by step. It can establish links between tasks.

> *LLM bir planlama yapar ve bunu adım adım üretir. Görevler arasında bağ kurabilir.*

What is a ready-made LLM: Models that have been pretrained with a large dataset and made directly available for use. We can use these models through an interface without technical knowledge. There is no need to be a programmer.

> *Hazır LLM Nedir: Önceden büyük veri seti ile eğitilmiş ve doğrudan kullanıma sunulmuş modellerdir. Bu modelleri teknik bilgi olmadan ara yüzden kullanabiliriz. Yazılımcı olmaya gerek yoktur.*

API Integration: An API lets applications talk to each other. For LLMs, it means running the model not only from an interface but from within an application. It works like this:

> *API Entegrasyonu: API uygulamaların birbiri ile konuşmasını sağlar. LLM'de ise modelin sadece ara yüzden değil uygulama içinden çalıştırmak anlamındadır. şöyle çalışır:*

An API key is obtained.

> *API Anahtarı alınır.*

It is modeled with an HTTP request.

> *HTTP isteği ile modellenir.*

The prompt is given.

> *Prompt verilir.*

The model's response is used in the application.

> *Model yanıtı uygulamada kullanılır.*

Pricing is based on usage. Payment is based on the tokens sent.

> *Kullanıma göre fiyatlandırma yapılır. Gönderilen token bazlı ödemedir.*

Used when we want to integrate an LLM into our own system, if we are aiming at automation or product development.

> *Kendi sistemimize LLM Entegre etmek istediğimizde kullanılır. Otomatikleştirme veya ürün geliştirme hedefliyorsak.*

Model training process:

> *Model eğitim süreci:*

1) model + data selection

> *1) model + veri seçimi*

2) data cleaning and preprocessing

> *2) veri temizleme ve ön işleme*

3) evaluation and tuning

> *3) değerlendirme ve ayarlama*

Lightweight training with fine-tuning and LoRA:

> *Fine-tunning ve LoRA ile hafif eğitim:*

LoRA is a method of changing small-weight layers.

> *Lora küçük ağırlıklı katmanları değiştirme yöntemidir.*

Tool use of LLMs: LLMs do not interact with systems; tool use is the ability of LLMs to communicate with external systems.

> *LLM'lerin araç kullanımı: LLM'ler sistemlerle etkileşime geçmezler araç kullanımı LLM'lerin dış sistemlerle iletişime geçebilmesidir.*

prompt:

> *prompt:*

Explanation + example

> *Açıklama+örnek*

clear and understandable prompt

> *net ve anlaşılır prompt*

context window:

> *bağlam penceresi:*

The model does not forget part of the context. The number of tokens an LLM can read at once is important.

> *Model bağlamın bir kısmını unutmaz. LLM'in aynı anda okuyabildiği token önemlidir.*

The part that exceeds the context is forgotten.

> *Bağlamı aşan kısım unutulur.*

MCP (Model Context Prompt):

> *MCP(Model Context Prompt):*

It is one of the methods of using LLMs more systematically and efficiently. 3 elements work together: Model, context, prompt

> *LLM'leri daha sistemli verimli kullanmanın yöntemlerinden biridir. 3 öge birlikte çalışır. Model,context,prompt*

Model: which AI will be used?

> *Model: hangi yapay zeka kullanılacak?*

Context: what are we talking about?

> *Context: ne hakkında konuşuyoruz?*

Prompt: What do we want it to do?

> *Prompt: Ne yapmasını istiyoruz?*

RAG: A system that enables LLMs to respond with more robust, more accurate information. An LLM's memory is limited. It does not know what happened after the date it was trained. If we give it external information (search engine, documents, etc.), the model pulls data from there and learns. It is combining LLMs with external information sources.

> *RAG: LLM'lerin daha sağlam daha doğru bilgi ile yanıt vermesini sağlayan sistemdir. LLM hafızası sınırlıdır. Eğitildiğinde tarihten sonra olanları bilmez. Ona harici bilgiler verirsek (Arama motoru, belgeler vs.) Model oradan veri çeker ve öğrenir. LLM'leri dış bilgi kaynakları ile birleştirmektir.*

Search + writing = RAG

> *Arama+yazma=RAG*

Since LLMs are trained in the past,

> *LLM'ler geçmişte eğitildiği için*

they do not know new information and retraining them is very difficult. Therefore, up-to-date data can be obtained with RAG and hallucination can be reduced.

> *yeni bilgiyi bilmezler ve tekrar eğtilmesi çok zordur. Bu yüzden RAG ile güncel veri alınabilir ve halisünasyon azaltılabilir.*

We will take the data, convert it into a vector DB, and then do RAG by combining it with the LLM. This process is called RAG.

> *Veriyi alıcaz bunu vektör DB'ye çeviricez sonrasında ise LLM ile birleştirerek RAG yapıcaz. Bu sürece RAG denir.*

transformers library: A very important library on Hugging Face; with a few lines of code we can load and run an LLM.

> *transformers kütüphanesi: Hugging Face'de bulunan çok öneml bi kütüphane bir kaç satır kodla LLM'i yükleyip çalıştırabiliyoruz.*

LangChain: Open-source tools developed for building LLM-based applications. It sets up multi-step workflows and tools.

> *LangChain: LLM tabanlı uygulama gelişitirilimiş açık kaynaklı araçlardır. Çok adımlı iş akışları ve araçlar kurar.*

It enables the model to be used not for a single task but in multi-flow tasks.

> *Modeli tek bir görev değil çok akışlı görevlerde kullanılmasını sağlar.*

LlamaIndex: Enables LLMs to talk with private data. We can teach LLMs to talk with our own data.

> *LlamaIndex: LLM'lerin özel verilerle konuşmasını sağlar. LLM'lere kendi verilerimizle konuşmayı öğretebiliriz.*

Both are used in RAG and AI Agent structures.

> *İkiside RAG ve AIAgent yapılarında kullanılır.*

With LangChain we can build multiple flows. (Read the document, summarize, turn it into an email...)

> *LangChainle birden fazla akış kurabiliriz. (Belgeyi oku, özetle, maile dönüştür...)*

LlamaIndex: first read this document, process it, and have it produce a response based on the data.

> *LLamaIndex şu belgeyi önce oku işle ve veriye dayalı yanıt ürettir.*

LLM OS: Thinking of an LLM not just as a text generator but as an OS. LLM = OS. LLMs can coordinate themselves through inputs and outputs. With agents and tools, the OS form of the application emerges.

> *LLM OS: LLM sadece bir metin üreticisi değil bir OS gibi düşünmesidir. LLM=OS. LLM'ler girdi çıktılar ile kendini koordine edebiliyor. Ajanlar, araçlar ile uygulamanın OS hali gelir.*

LLM: The part that decides and directs

> *LLM: Karar veren ve yönlendiren kısım*

Tools: The part that performs external operations.

> *Tools: dış işlemleri gerçekleştiren kısım.*

Memory: Structures that keep the past.

> *Memory: geçmişi tutan yapılar.*

Agents: Structures that manage and try to reach a goal in order to achieve it.

> *Ajanlar: Bir hedefe ulaşmak için bunu yöneten ve ulaşmaya çalışan yapılar.*

Instead of building a separate structure for each task, we can solve the job with a single structure. It provides modularity.

> *Her görev için ayrı ayrı yapı kurmak yerine tek bir yapı ile işi çözebiliyoruz. Modülerlik sağlıyor.*

Compression: LLMs are very powerful and large models. Large models need powerful hardware. We can reduce the size of the model and increase its speed.

> *Kompresyon: LLM'ler çok güçlü ve büyük modeller. Büyük modeller güçlü donanıma ihtiyaç duyar. Modelin boyutunu küçültüp hızını arttırabiliyoruz.*

Quantization: Serves to represent weights in a smaller format.

> *Kuantiazsyon: Ağırlıkları küçük formatta temsil etmeye yarar.*

pruning: Deleting unnecessary connections in the model.

> *prunning: Modeldeki gereksiz bağlantıları silmek.*

distillation: A small model learning the large model.

> *distillation: küçük modelin büyük modeli öğrenmesidir.*

weight sharing: storing similar weights by grouping them.

> *weight sharing: benzer ağırlıkları gruplayarak saklamak.*

Ucanble Hub: A platform that gathers models developed in Turkey in one place.

> *Ucanble Hub: Türkiyede geliştirilen modelleri bir yere toplayan platformdur.*

Data privacy in LLMs: LLMs are trained with large texts. The model can learn private information in these texts. It may contain personal data. Not ethical...

> *LLM'lerde veri gizliliği: LLM'ler büyük metinlerle eğitilir. Modül bu metinlerde özel bilgileri öğrenebiliyor. Kişisel verileri içerebiliyor. Etik değil...*

A user can trigger this with a suitable prompt. The training data in the model should be filtered.

> *Bir kullanıcı uygun bir prompt ile bunu tetikleyebilir. Modeldeki eğitim verileri filtrelenmelidir.*

Model Bias and Fairness:

> *Modelin Yanlılığı ve Adalet:*

The model behaving in a biased way toward some groups. For example, treating women as more emotional and men as more logical. For example, different schemas such as race, religion, age and profession may be found in the data in the dataset.

> *Modelin bazı gruplara yanlı davranmasıdır. Mesela kadınlara daha duygusal Erkeklere daha mantıksal davranmasıdır. Örneğin veri setindeki verilerde ırk din yaş meslek gibi farklı şemalar bulunabilir.*

LLM Security: LLMs produce the most probable word in response to the incoming text. Therefore they can generate in response to a prompt that looks correct. They can be fooled.

> *LLM Güvenliği: LLM'ler gelen metne karşılık en olası kelimeyi üretirler. Dolayısıyla doğru gibi görünen bir prompta üretim yapabilirler. Kandırılabilirdirler.*

LLM Grooming: A model can abuse a friendly conversational style. The model can explain harmful information in soft language. It is a manipulation method. LLMs do not say where they learned information from. It is a risky subject.

> *LLM Grooming: Bir model samimi konuşma tarzını kötüye kullanabilir. Model zararlı bilgileri yumuşak bir dil ile anlatabilir. Manipülasyon yöntemidir. LLM'ler nereden bilgi öğrendiğini söylemezler. Riskli bir konudur.*